

Vertrauen ist gut

Unsicherheit messen ist besser

Wie wir die (Un)Sicherheit von LLM-Antworten sichtbar machen.

LLMs klingen oft sehr überzeugend – auch wenn Annahmen wackeln. Wir erkennen, wo ein Modell wirklich sicher ist und wo Unsicherheit entsteht (Reasoning-Schritte). So können wir gezielt nachfragen, nachrechnen und Risiken senken.

Frage: Wie viele Beine haben 10 Hühner?

- Schritt:** Gesucht ist die Gesamtzahl Beine.
- Schritt:** Ein Huhn hat **4 Beine**
- Schritt:** Rechnung: $10 \cdot 4 = 40$
- Finale Antwort:** 40 Beine



Unsicherheit!

Hohe Sicherheit in Finaler Antwort

Aggregationsmetriken

- Ein Wort $\approx$ ein Token; jedes Token hat eine Wahrscheinlichkeit.
- Verschiedene Aggregationen dieser Token-Wahrscheinlichkeiten
- Zwei Setups:
 - Final-Answer** only: nur Antwort-Tokens.
 - Reasoning-aware:** **Keyword-Tokens** aus der Reasoning-Kette, **gewichtet** mit Importance-Scores (1–10).

Wie messen wir Unsicherheit?

Selbsteinschätzung

- Modell schätzt seine **eigene Sicherheit** explizit („Wie sicher ist deine Antwort?“).
- Vergleich zweier Setups:
 - Final-Answer** only.
 - Mit Zusatzkontext** aus der Reasoning-Kette (Keywords/Schritte).

Output: Confidence $\in [0,1]$ (höher = sicherer).

Methodik

Setup

- Modell: Llama-3.1-8B-Instruct
- Datensätze: 5 insgesamt – 3× Mathe (GSM8K, SVAMP, ASDiv), 2× Multi-Hop-QA (HotpotQA, 2WikiMHQA)
- Pro Setup: 5 Runs

Antwortgenerierung

- LLM erzeugt **Reasoning-Kette** und **Final Answer**
- Zwei Ansätze: **CoT** (Ausführliche Reasoning-Schritte) & **CoD** (Stichwortartige Reasoning-Schritte)

Keyword-Extraction & Importance Scoring

- Zweiter LLM-Call: **Keywords** aus der Reasoning-Kette **extrahieren**
- Jedem Keyword wird ein **Wichtigkeits-Score** (1–10) zugewiesen

Konfidenz berechnen

- Aggregationsmetriken** aus Token-Wahrscheinlichkeiten: *Probas-Mean*, *Probas-Min*, *Token-SAR*
- Varianten: **Final-Answer-only** (-bl) vs. **Reasoning-aware** (mit Keywords und Gewichtung)
- Self-Evaluation:** *P-True*, *Self-Probing* (ebenfalls als -bl und verschiedene Varianten mit Reasoning-Kontexten)

Ground Truth vs. LLM-Antwort

- Mathe: numerische Antwort via Regex
- Multi-Hop-QA: LLM-Judge bewertet Korrektheit

Qualitätsmaße

- Berechnung anhand von **Korrekt-/Falsch-Labels** und der **vorhergesagten Konfidenz**.
- AUROC:** Wie gut trennt Konfidenz richtige vs. falsche Antworten
- ECE & Reliability Curves:** messen Kalibrierung
- Ziel: **Hohe Trennung** und **gut kalibrierte** Konfidenzen

Antwortgenerierung

Keyword Extraction and Importance Scoring

output.json

Ground Truth vs LLM-Antwort

true_labels.json

Qualitätsmasse Berechnen

Confidences Berechnen

probas-min-bl

probas min

...

Self-Probing-bl

...

Resultate

1) Reasoning-aware Keyword-Aggregation (grün) vs. Final-Answer-Baseline (rot)

→ über alle Datensätze & Aggregationsmetriken **höhere AUROC** und **niedrigere ECE** (siehe Plot rechts).

2) Self-Evaluation (P-True, Self-Probing)


→ **AUROC** nahe zufällig, **Kalibrierung schwach**;

P-True: geringe Konfidenz-Dynamik;

Self-Probing: Konfidenz korreliert kaum mit Accuracy.

3) CoD (Stichwortartige Reasoning-Schritte)

→ ca. **80 % weniger Tokens**, **Unsicherheitsqualität** weitgehend **stabil**; **Accuracy +2,85 %-Punkte**.



Studiengang/ Semester: Informatik 25FS

Projekttitel: Unsicherheitsabschätzung in Large Language Models mittels Reasoning-Strategien

Diplomand: Mauro Hirt

Externer Experte: Frefel Dominik

Dozent/Betreuer: Prof. Dr. Daniel Perruchoud, daniel.perruchoud@fhnw.ch
Stephan Heule, stephan.heule@fhnw.ch

Github-Repo (QR)

- Zusätzliches Experiment: Tree-of-Thought**
Denken als Suchbaum – Pfadwahl nach Unsicherheit.
- Paper (PDF):** vollständige Auswertung & Diskussion.
- Code & Materialien:** Code, Datensätze, Outputs etc.

